

Un Framework Multi-Agente LLM para la Automatización Autónoma de Procesos Empresariales: Caso de Estudio en Procurement

Edurne Martínez de Contrasta^{a,b}

^a *Máster en Big Data y Business Analytics, Universidad Alfonso X el Sabio, Madrid, España*

^b *PROJENER.AI SL, Madrid, España*

Abstract

Los sistemas tradicionales de Automatización Robótica de Procesos (RPA) automatizan procesos empresariales mediante reglas if-then, pero carecen de capacidad de razonamiento ante excepciones. Este trabajo propone, implementa y evalúa un framework multi-agente basado en Modelos de Lenguaje de Gran Escala (LLMs) para la automatización end-to-end de procesos de procurement empresarial. El sistema implementa cinco agentes especializados con roles empresariales (*Requester, Procurement, Finance, Legal, Compliance*) orquestados con CrewAI, cada uno con acceso exclusivo a sus propias herramientas a través de seis APIs mock que simulan sistemas ERP, plataformas CRM y bases de datos regulatorias.

El experimento compara ocho variantes del sistema (M1–M5, M2x, M3b, M4b) sobre un conjunto de 50 casos de procurement en tres niveles de complejidad, utilizando los modelos `llama-3.1-8b-instant` y `llama-3.3-70b-versatile` de Groq. Los resultados revelan cuatro hallazgos principales:

- (1) el agente único con contexto expandido (M2x: $ARR = 84\%$) supera al sistema multi-agente homogéneo con igual presupuesto de tokens (M3: $ARR = 68\%$), validando empíricamente la hipótesis de *compute equivalence*; sin embargo, el análisis de robustez muestra alta variabilidad en M2 ($ARR = 92\% \pm 11.3$ pp) frente a la estabilidad de M4 ($ARR = 98.7\% \pm 0.9$ pp);

Email address: `edurne.martinez@uax.es` (Edurne Martínez de Contrasta)

- (2) introducir diversidad de modelos produce el mayor salto de rendimiento (+32pp ARR, de M3 a M4);
- (3) el ablation study demuestra que eliminar los agentes Legal y Procurement aumenta el ARR en 20 pp pero anula la HDA, evidenciando el trade-off entre automatización y detección de riesgo; y
- (4) la reproducibilidad se confirma al 100% con `temperature=0.0`.

El hallazgo central es que la arquitectura multi-agente requiere modelos con capacidad suficiente para beneficiarse de la especialización.

Keywords: Sistemas multi-agente, Modelos de Lenguaje de Gran Escala, Automatización de procurement, CrewAI, Human-in-the-Loop, Compute equivalence, Diversidad de modelos, IA empresarial, Ablation study, Reproducibilidad

1. Introducción

Considérese el siguiente escenario: un técnico de mantenimiento necesita adquirir una pieza de repuesto valorada en 150 euros. El proveedor está homologado, el presupuesto disponible existe y la necesidad es inmediata. A pesar de ello, la solicitud tardará entre tres y siete días laborables en recibir una decisión, recorriendo secuencialmente los departamentos de compras, legal, finanzas y compliance. El coste medio de tramitar ese pedido asciende a 112 euros adicionales en tiempo de personal (Hackett Group, 2023). El cuello de botella no reside en la burocracia como tal, sino en que los sistemas diseñados para automatizarla no son capaces de razonar.

Los sistemas RPA actuales ejecutan con eficacia tareas estructuradas y repetitivas, pero fracasan sistemáticamente ante cualquier desviación: un proveedor con alerta de conflicto de interés, un contrato con cláusula de exclusividad o un importe que supera el umbral de aprobación del área.

El campo de los sistemas multi-agente basados en LLMs ofrece una respuesta técnica. Frameworks como AutoGen (Wu et al., 2023), CrewAI (CrewAI, 2024) y LangGraph permiten construir equipos de agentes que colaboran, razonan y adaptan su comportamiento ante excepciones. ChatDev (Qian et al., 2023) mostró que equipos de agentes pueden superar a agentes individuales en tareas complejas; Park et al. (2023) documentaron comportamientos sociales emergentes en comunidades de agentes LLM.

Este trabajo aborda la brecha de evidencia empírica con cuatro contribuciones:

- (1) diseño e implementación de un framework multi-agente completo para procurement con cinco agentes especializados y seis herramientas empresariales simuladas;
- (2) un dataset de 50 casos con ground truth anotado en tres niveles de complejidad, siguiendo la metodología de WorkArena (Drouin et al., 2024) y AgentBench (Liu et al., 2023);
- (3) evaluación de ocho variantes del sistema, incluyendo ablation study ejecutado, comparativa de compute equivalence y análisis de diversidad de modelos; y
- (4) verificación de reproducibilidad y análisis de robustez estadística mediante tres réplicas independientes.

Pregunta de investigación.. ¿Puede un sistema multi-agente basado en LLMs automatizar un proceso de procurement end-to-end, adaptarse a excepciones y superar a los enfoques RPA tradicionales en calidad de decisión — y bajo qué condiciones arquitectónicas y de modelo se produce esa ventaja?

El artículo se estructura como sigue. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe la arquitectura. La Sección 4 detalla el setup experimental. La Sección 5 presenta los resultados. Las Secciones 6, 7 y 8 profundizan en ablation, compute equivalence y diversidad de modelos. La Sección 9 discute los hallazgos y la Sección 10 presenta las conclusiones.

2. Trabajo Relacionado

2.1. Sistemas multi-agente LLM

Wu et al. (2023) introdujeron AutoGen, framework de conversación multi-agente que permite a los LLMs colaborar mediante mensajes estructurados. CrewAI (CrewAI, 2024) extiende este paradigma con roles, tareas y equipos inspirados en organizaciones humanas. Park et al. (2023) demostraron comportamientos sociales emergentes en comunidades de agentes LLM. ChatDev (Qian et al., 2023) aplicó el paradigma al desarrollo de software, mostrando que equipos de agentes especializados superan a agentes individuales.

2.2. Automatización de procesos empresariales

Los sistemas RPA (UiPath, Automation Anywhere) automatizan tareas repetitivas basadas en reglas pero fallan ante excepciones. WorkArena (Drouin et al., 2024) y TaskBench (Lù et al., 2023) proporcionan entornos de evaluación para agentes en procesos empresariales. ToolBench (Qin et al., 2023) demostró que los LLMs pueden aprender a usar miles de APIs reales. APIBench (Patil et al., 2023) evalúa la capacidad de los LLMs para generar llamadas a APIs correctas. OSWorld (Xie et al., 2024) evalúa agentes sobre sistemas operativos completos; a diferencia de OSWorld, este trabajo se centra en procesos empresariales estructurados con roles definidos.

2.3. Compute equivalence y diversidad de modelos

Wu et al. (2023) plantean que la comparación justa es “5 agentes con X tokens vs. 1 agente con $5X$ tokens”. Este trabajo ejecuta esa comparación empíricamente. En ensemble learning, la diversidad de modelos reduce la correlación de errores (Dietterich, 2000).

3. Framework Propuesto

3.1. Arquitectura general

El sistema se estructura como un Grafo Acíclico Dirigido (DAG) donde cada nodo representa un agente especializado y las aristas el flujo de información. El orquestador CrewAI gestiona la secuencia de ejecución. En M5, el agente Compliance tiene reglas explícitas de escalación HiL.

3.2. Las nueve variantes del sistema

4. Setup Experimental

4.1. Dataset: 50 casos de procurement

Se diseñaron 50 casos con ground truth anotado en tres niveles: *Simple* (C01–C20), *Medio* (C21–C38) y *Complejo* (C39–C50). Siguiendo la metodología de WorkArena (Drouin et al., 2024) y AgentBench (Liu et al., 2023).

Table 1: Endpoints de APIs mock, agentes propietarios y función en el sistema.

API	Endpoint	Función en el sistema
Catálogo Proveedores	GET /api/proveedores/{id}	Valida estado y alertas de conflicto de interés
Verificación Presupuestaria	GET /api/presupuesto/{dept}	Comprueba fondos y nivel de aprobación
Base Regulatoria	GET /api/normativa/{cat}	Detecta GDPR, CE, PRL, AESA, normativa sanitaria
Validación Contractual	POST /api/contratos/validar	Analiza cláusulas de riesgo (exclusividad, IP, penalizaciones)
Formulario Solicitud	POST /api/solicitudes/nueva	Registra metadatos y abre el caso
Escalación HiL	POST /api/escalacion/humano	Escala con resumen, opciones y recomendación

Table 2: Resumen de variantes del sistema. M1, M2 y M4 reportan media $\pm$ desv. típica (3 réplicas). El resto reporta ejecución única. ARR: Tasa de Resolución Autónoma; HDA: Precisión Detección HiL; DER: Tasa de Error; PT: Tiempo.

Modelo	Config.	ARR	HDA	DER	PT (s)	Propósito
M1 — RPA	Reglas if-then	100% $\pm$ 0.0 pp	0% $\pm$ 0.0 pp	34% $\pm$ 0.0 pp	$\approx$ 0	Baseline mínimo
M2 — Single (200 tok)	8b $\times$ 1 ag.	92% $\pm$ 11.3 pp	10.3% $\pm$ 14.5 pp	27.3% $\pm$ 3.8 pp	0.31	Referencia LLM
M2x — Single (750 tok)	8b $\times$ 1 ag.	84%	23.1%	28%	0.40	Compute equivalence
M3 — Multi hom.	8b $\times$ 5 ag.	68%	30.8%	28%	1.74	Sistema principal
M3b — Ablation 3 ag	8b $\times$ 3 ag.	88%	0%	30%	0.77	Ablation Legal+Proc
M4 — Multi mixto	8b $\times$ 4+70b $\times$ 1	98.7% $\pm$ 0.9 pp	5.1% $\pm$ 3.6 pp	27.3% $\pm$ 0.9 pp	1.69	ÓPTIMO
M4b — Multi potente	70b $\times$ 5 ag.	98%	0%	26%	2.40	Hom. potente
M5 — Multi + HiL	8b $\times$ 5 + HiL	98%	0%	28%	1.56	HiL activo
M5b — Clasif. Incert.	2 llamadas $\times$ 1 ag	94%	23.1%	22%	2.85	Mejor HDA

4.2. Métricas

ARR Tasa de Resolución Autónoma: % casos resueltos sin HiL. Objetivo: $>70\%$.

HDA Precisión de Detección HiL: % casos que requieren HiL y son escalados correctamente. Objetivo: $>90\%$.

DER Tasa de Error de Decisión: % decisiones incorrectas vs. ground truth. Objetivo: $<10\%$.

PT Tiempo de proceso medio por caso (segundos).

4.3. Stack tecnológico

- Framework: CrewAI (Python 3.12, Windows 10, Jupyter Lab)
- LLM principal: llama-3.1-8b-instant vía Groq API
- LLM decisor M4/M4b: llama-3.3-70b-versatile vía Groq API
- Temperature: 0.0
- Código completo: <https://github.com/Edurne0781/multiagent-procurement-llm>

4.4. Análisis de robustez estadística

Se ejecutaron tres réplicas independientes de M1, M2 y M4. M1 es perfectamente determinista ($\sigma = 0$). M2 muestra alta variabilidad (σ ARR = 11.3 pp). M4 es el más estable (σ ARR = 0.9 pp).




Figure 1: Robustez estadística: media $\pm$ desviación estándar de ARR, HDA y DER para M1, M2 y M4 sobre 3 réplicas independientes.

Table 3: Resultados individuales por réplica para M1, M2 y M4.

Modelo	Réplica 1	Réplica 2	Réplica 3	Media $\pm \sigma$
M1 — ARR	100%	100%	100%	100% ± 0.0 pp
M1 — HDA	0%	0%	0%	0% ± 0.0 pp
M1 — DER	34%	34%	34%	34% ± 0.0 pp
M2 — ARR	76%	100%	100%	92% ± 11.3 pp
M2 — HDA	30.8%	0%	0%	10.3% ± 14.5 pp
M2 — DER	22%	28%	32%	27.3% ± 3.8 pp
M4 — ARR	100%	98%	98%	98.7% ± 0.9 pp
M4 — HDA	0%	7.7%	7.7%	5.1% ± 3.6 pp
M4 — DER	26%	28%	28%	27.3% ± 0.9 pp

5. Resultados

5.1. Tabla comparativa global

Ver Tabla 2 para la comparación completa. La Figura 2 ofrece una visión visual de las tres métricas principales.




Figure 2: Comparativa de métricas principales M1–M5: ARR (objetivo $>70\%$), HDA (objetivo $>90\%$) y DER (objetivo $<10\%$).

5.2. Análisis por modelo

M1 — Baseline RPA. ARR = 100% porque nunca escala al humano. HDA = 0% y DER = 34% (1 de cada 3 decisiones incorrecta). Reproduce exactamente la limitación documentada de los sistemas RPA.

M2 — Agente único LLM (200 tokens). ARR = 76%, supera el objetivo $>70\%$. DER = 22%, mejora de 12 pp sobre M1. HDA = 30.8%. El modelo más eficiente en tiempo (PT = 0.26 s).

M3 — Multi-Agente homogéneo (8b×5). ARR = 68%, inferior a M2 (76%). Con `llama-3.1-8b-instant`, la fragmentación del contexto entre 5 agentes perjudica la calidad de decisión. La arquitectura multi-agente no aporta ventaja con modelos pequeños.

M4 — Multi-Agente mixto (8b×4 + 70b×1). ARR = 100%, el mayor salto del experimento (+32 pp sobre M3). El agente Compliance con `llama-3.3-70b` toma decisiones cualitativamente mejores. Configuración óptima en coste/rendimiento.

M4b — Multi-Agente homogéneo potente (70b×5). ARR = 98%, prácticamente igual que M4 pero $2.7\times$ más caro. Confirma que los agentes auxiliares con 8b son suficientes.

M5 — Multi-Agente + HiL activo.. ARR=98%. Las reglas explícitas de escalación no aumentaron la HDA (0%), indicando que llama-3.1-8b carece de capacidad suficiente.

M5b — Clasificador de incertidumbre.. ARR = 94%, HDA = 23.1%, DER = 22%.
Análisis detallado en la Sección 6.

5.3. Análisis de coste computacional

Table 4: Análisis de coste computacional y tokens por modelo.

Modelo	Tok/caso	Tok total	Llamadas	Coste equiv.	Observación
M1 — RPA	0	0	0	\$0.0000	Sin LLM
M2 — Single	200	10.000	1	\$0.0012	Más eficiente
M2x	750	37.500	1	\$0.0045	Equiv. a M3
M3 — Multi	750	37.500	5	\$0.0045	M2x lo supera
M3b	450	22.500	3	\$0.0027	Ahorro 40%
M4 — Mixto	750	37.500	5	\$0.0065	ARR=100%
M4b	750	37.500	5	\$0.0120	2.7× M4
M5 — HiL	875	43.750	5	\$0.0053	Mejor ARR/coste

6. Ablation Study

6.1. A3 ejecutado — 3 agentes vs. 5 (M3b)

Eliminar Legal y Procurement sube el ARR de 68% a 88% (+20 pp) pero la HDA cae de 30.8% a 0%. Esto cuantifica el trade-off fundamental: la especialización no maximiza la automatización bruta sino la calidad supervisada de decisión, exactamente como predice la teoría de ventaja comparativa de Ricardo (1817).

6.2. Análisis de grafos

Finance es el nodo con mayor betweenness centrality (4), actuando como puente entre la validación operativa y la decisión regulatoria. En términos de Granovetter (1973), Finance representa el “lazo débil” más crítico del sistema.

Scatter plot showing Autonomous Resolution Rate (%) on the Y-axis versus Tiempo de proceso (seg/caso) on the X-axis. The plot includes a green shaded area labeled 'Zona objetivo ARR > 70%' and a red dashed line at 70% ARR. A teal line connects M2 Single Agent and M2: mejor equilibrio ARR/eficiencia. Data points are labeled: M1 RPA (blue), M2 Single Agent (teal), M2: mejor equilibrio ARR/eficiencia (teal), M3 Multi-Agent (blue), M4 Mixto (red), M5 H (purple).

Modelo	Tiempo de proceso (seg/caso)	Autonomous Resolution Rate (%)
M1 RPA	0.00	100
M2 Single Agent	0.25	76
M2: mejor equilibrio ARR/eficiencia	0.60	81
M3 Multi-Agent	1.75	68
M4 Mixto	1.75	100
M5 H	1.60	98

Figura 3: Distribución de decisiones por modelo (50 casos)

Modelo	Aprobado	Rechazado	Escalado HiL	Error (rate limit)
M1 RPA	31	19	0	0
M2 Single	26	13	11	0
M3 Multi	31	7	4	6
M4 Mixto	42	8	0	0
M5 HiL	39	9	0	0

10




Figure 5: ARR frente al coste en tokens (izq.) y consumo de tokens por modelo (dcha.).

Table 5: Experimentos del ablation study.

ID	Experimento	ARR	HDA	Hallazgo principal
A1	Sin Legal (planif.)	—	—	Casos con cláusulas complejas pierden calidad
A2	Sin Compliance (planif.)	—	—	Casos regulatorios no se bloquean
A3	3 ag vs 5 (M3b, ejec.)	88% vs 68%	0% vs 30.8%	+20 pp ARR pero destruye HDA
A4	Sin HiL (M3 vs M5)	68% vs 98%	30.8% vs 0%	HiL mejora ARR pero no HDA

Table 6: Métricas de centralidad en la red de comunicación.

Agente	Grado total	Grado entrada	Betweenness	Rol
Requester	1	0	0	Fuente
Procurement	2	1	3	Intermediario
Finance	2	1	4	Nodo más central
Legal	2	1	3	Intermediario
Compliance	1	1	0	Sumidero — decide




Figure 6: Red de comunicación entre agentes: topología lineal (izq.) y centralidad por agente (dcha.).

Table 7: Tasa de resolución por nivel de complejidad.

Modelo	Simple	Medio	Complejo	Total	Observación
M2 Single	100%	100%	100%	100%	Sin errores
M3 Multi	95%	83.3%	83.3%	88%	Degradación en complejos
M4 Mixto	100%	100%	100%	100%	Sin degradación
M5 HiL	100%	94.4%	100%	98%	Un error rate-limit
M3b Ablation	95%	88.9%	83.3%	90%	Más robusto que M3




Figure 7: Tasa de resolución por nivel de complejidad para cada modelo.

6.3. Convergencia por nivel de complejidad

6.4. M5b — Clasificador de incertidumbre

M5b es un sistema de dos etapas: un agente Evaluador de Incertidumbre analiza los factores de riesgo y emite un nivel de confianza (alta/baja); si es baja, el caso se escala al humano; si es alta, un Gestor Senior decide. HDA sube de 0% a 23.1% con 0 falsos positivos.

7. Comparativa Multi-Agente vs. Agente Único con Compute Equivalente

Table 8: Comparativa de compute equivalence.

Modelo	Tok	Ag.	ARR	HDA	DER	PT	Conclusión
M2 Single	200	1	76%	30.8%	22%	0.31s	Referencia
M2x Expandido	750	1	84%	23.1%	28%	0.40s	Mismo budget que M3
M3 Multi	750	5	68%	30.8%	28%	1.74s	M2x lo supera
M3b Ablation	450	3	88%	0%	30%	0.77s	3 ag. más efíc.

M2x (84%) supera a M3 (68%) con el mismo presupuesto de tokens, validando empíricamente la hipótesis de compute equivalence (Wu et al.,




Figure 8: M5 vs M5b: comparativa de métricas (izq.) y análisis de las 13 escalaciones HiL requeridas (dcha.).

2023): con `llama-3.1-8b-instant`, la arquitectura multi-agente no aporta valor arquitectónico. La ventaja emerge únicamente cuando el modelo tiene capacidad suficiente para beneficiarse de la especialización.

8. Diversidad de Modelos como Variable Experimental

Table 9: Configuraciones de diversidad de modelos.

Config.	Modelos	ARR	HDA	DER	PT	Interpretación
M3 Hom. peq.	8b×5	68%	30.8%	28%	1.74s	Errores correlacionados
M4 Mixto	8b×4+70b×1	100%	0%	26%	1.74s	ÓPTIMO
M4b Hom. pot.	70b×5	98%	0%	26%	2.40s	2.7× más caro

El mayor salto es +32 pp ARR entre M3 y M4 con los mismos tokens y agentes. En sistemas multi-agente *la elección del modelo importa más que la arquitectura*.

9. Discusión

9.1. Hallazgos principales

El hallazgo más importante es la confirmación empírica de la hipótesis de compute equivalence: M2x (ARR = 84%) supera a M3 (ARR = 68%) con

Figura 4: Perfil de rendimiento por modelo (radar)




Figure 9: Perfil de rendimiento por modelo (gráfico radar).

el mismo presupuesto. El sistema resuelve solicitudes en 0.26–2.85 segundos frente a 3–7 días del proceso manual (Hackett Group, 2023): una reducción superior al 99%.

El segundo hallazgo es el trade-off automatización/detección de riesgo (ablation A3): eliminar agentes especializados sube el ARR 20 pp pero destruye la HDA.

El tercer hallazgo es la superioridad de la estrategia mixta (M4): modelo potente en el decisor y ligeros en los auxiliares da los mismos resultados que todos potentes a un 37% del coste.

9.2. Conexión con teorías organizacionales

Ricardo (1817) — ventaja comparativa: el ablation cuantifica que Legal y Procurement tienen ventaja relativa en detectar sus riesgos específicos (+30.8 pp HDA).

Granovetter (1973) — lazos débiles: Finance (betweenness = 4) es el puente más crítico del sistema.

Olson (1965) — acción colectiva: HDA = 0% en M4 ilustra que cuando todos pueden detectar el riesgo, nadie lo escala.

9.3. Limitaciones

Ninguna configuración superó HDA > 90%. Esto apunta a que la especialización de roles puede inhibir la detección de riesgo sistémico — cuando cada agente sólo ve su fragmento, los casos con riesgo transversal no se escalan.

10. Conclusiones y Trabajo Futuro

M4 alcanzó $\text{ARR} = 98.7\% \pm 0.9$ pp, procesando solicitudes en 1.74 segundos a \$0.0065 por caso, mejorando la tasa de error del RPA en 8 pp.

El hallazgo más inesperado fue que M3 (5 agentes) fue superado por M2 (1 agente): con llama-3.1-8b, fragmentar el contexto perjudica más de lo que la especialización ayuda. El umbral de capacidad se sitúa entre 8B y 70B parámetros.

10.1. Contribuciones

- (1) Framework multi-agente completo con 5 agentes, 6 herramientas y soporte HiL en CrewAI/Python 3.12.
- (2) Dataset de 50 casos con ground truth en tres niveles de complejidad.

- (3) Evidencia empírica sobre compute equivalence, diversidad de modelos y especialización mediante ablation study ejecutado.
- (4) Análisis de robustez con 3 réplicas: σ ARR = 11.3 pp para 8B frente a σ ARR = 0.9 pp para la arquitectura mixta.

10.2. Trabajo futuro

- (1) Evaluar si $HDA > 90\%$ es alcanzable o el problema es estructural.
- (2) Extender M5b con factores regulatorios específicos (GDPR, AESA, CE).
- (3) Replicar en onboarding, incident management, compliance y análisis financiero.
- (4) Conectar con APIs live de ERP/CRM reales.
- (5) Investigar un agente integrador de síntesis transversal previo a la decisión de escalación.

Conclusión: La arquitectura multi-agente no es superior al agente único por defecto. Lo es cuando el modelo subyacente tiene capacidad suficiente para beneficiarse de la especialización. El camino hacia $HDA > 90\%$ no pasa por mejorar los modelos, sino por rediseñar cómo fluye la información entre ellos.

References

- CrewAI, 2024. CrewAI: Framework for orchestrating role-playing, autonomous AI agents. URL: <https://github.com/joaomdmoura/crewAI>. accessed: April 2026.
- Dietterich, T.G., 2000. Ensemble methods in machine learning, in: Kitter, J., Roli, F. (Eds.), Multiple Classifier Systems. Springer, Berlin, Heidelberg. volume 1857 of *Lecture Notes in Computer Science*, pp. 1–15. doi:10.1007/3-540-45014-9_1.
- Drouin, A., Gasse, M., Caccia, M., Laradji, I.H., Del Verme, M., Marty, T., Boisvert, L., Martel, M., Chapados, N., Lacoste, A., Pal, C., 2024. WorkArena: How capable are web agents at solving common knowledge work tasks?, in: arXiv preprint. URL: <https://arxiv.org/abs/2403.07718>, arXiv:2403.07718.
- Granovetter, M.S., 1973. The strength of weak ties. *American Journal of Sociology* 78, 1360–1380. doi:10.1086/225469.

- Hackett Group, 2023. Procurement Performance Study. Research Report. The Hackett Group. URL: <https://www.thehackettgroup.com>.
- Liu, X., Yu, H., Zhang, H., Xu, Y., Lei, X., Lai, H., Gu, Y., Ding, H., Men, K., Yang, K., Zhang, S., Deng, X., Zeng, A., Du, Z., Zhang, C., Shen, S., Zhang, T., Su, Y., Sun, H., Tang, J., 2023. AgentBench: Evaluating LLMs as agents, in: arXiv preprint. URL: <https://arxiv.org/abs/2308.03688>, arXiv:2308.03688.
- Lù, H., Zhao, Z., Zhang, C., Guo, B., Yu, Z., 2023. TaskBench: Benchmarking large language models for task automation, in: arXiv preprint. URL: <https://arxiv.org/abs/2311.18760>, arXiv:2311.18760.
- Olson, M., 1965. The Logic of Collective Action: Public Goods and the Theory of Groups. Harvard University Press, Cambridge, MA.
- Park, J.S., O’Brien, J.C., Cai, C.J., Morris, M.R., Liang, P., Bernstein, M.S., 2023. Generative agents: Interactive simulacra of human behavior, in: arXiv preprint. URL: <https://arxiv.org/abs/2304.03442>, arXiv:2304.03442.
- Patil, S.G., Zhang, T., Wang, X., Gonzalez, J.E., 2023. Gorilla: Large language model connected with massive APIs, in: arXiv preprint. URL: <https://arxiv.org/abs/2305.15334>, arXiv:2305.15334.
- Qian, C., Cong, X., Yang, C., Chen, W., Su, Y., Xu, J., Liu, Z., Sun, M., 2023. Communicative agents for software development, in: arXiv preprint. URL: <https://arxiv.org/abs/2307.07924>, arXiv:2307.07924.
- Qin, Y., Liang, S., Ye, Y., Zhu, K., Yan, L., Lu, Y., Lin, Y., Cong, X., Tang, X., Qian, B., Zhao, S., Tian, R., Xie, R., Zhou, J., Gerber, M., Liu, D., Li, H., Liu, X., Sun, M., 2023. ToolLLM: Facilitating large language models to master 16000+ real-world APIs, in: arXiv preprint. URL: <https://arxiv.org/abs/2307.16789>, arXiv:2307.16789.
- Ricardo, D., 1817. On the Principles of Political Economy and Taxation. John Murray, London.
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A.H., White, R.W., Burger, D., Wang, C., 2023. AutoGen: Enabling next-gen LLM applications via multi-agent

conversation framework, in: arXiv preprint. URL: <https://arxiv.org/abs/2308.08155>, arXiv:2308.08155.

Xie, T., Zhang, D., Chen, J., Li, X., Zhao, S., Cao, R., Hua, T., Cheng, Z., Shin, D., Lei, F., Liu, Y., Xu, Y., Zhou, S., Savarese, S., Xiong, C., Zhong, V., Yu, T., 2024. OSWorld: Benchmarking multimodal agents for open-ended tasks in real computer environments, in: arXiv preprint. URL: <https://arxiv.org/abs/2404.07972>, arXiv:2404.07972.

Appendix A. System Prompts de los Agentes

Agente Requester..

```
1 role: "Gestor de Solicitudes"
2 goal: "Registrar y estructurar solicitudes de compra."
3 backstory: "Primer punto de contacto. Registras
    solicitudes."
```

Agente Procurement..

```
1 role: "Especialista en Proveedores"
2 goal: "Validar proveedores y buscar alternativas."
3 backstory: "Proveedor: estado=X, opera=Y" [API catalogo]
```

Agente Finance..

```
1 role: "Analista Financiero"
2 goal: "Verificar presupuesto y aprobar o proponer
    reasignacion."
3 backstory: "Presupuesto: disponible=X EUR" [API
    presupuesto]
```

Agente Legal..

```
1 role: "Asesor Legal"
2 goal: "Revisar clausulas contractuales y detectar riesgos
    ."
3 backstory: "Legal: riesgo=X, firmar=Y" [API contratos]
```

Agente Compliance (decisor, M3/M5)..

```
1 role: "Auditor de Compliance"
2 goal: "Verificar normativa y decidir."
3 backstory: "Normativa: cumple=X, riesgo=Y.
4             [M5: ESCALA si conflicto interes, GDPR,
5             importe >50k EUR, riesgo critico]"
6 output: JSON {decision, razon, escala_hil}
```

Appendix B. Parámetros de Reproducibilidad

- Modelo principal: `groq/llama-3.1-8b-instant`
- Modelo decisor M4/M4b: `groq/llama-3.3-70b-versatile`
- Temperature: 0.0 (5/5 casos idénticos verificados: C01, C21, C39, C43, C50)
- Pausa entre casos: 4–8 segundos según modelo
- Reintentos máximos: 3 por caso
- Total llamadas LLM: M2=50; M3=250; M4=250; M5=250; réplicas=900
- Código: <https://github.com/Edurne0781/multiagent-procurement-llm> (Jupyter Lab, Python 3.12)